RELATÓRIO TÉCNICO

Previsão de Diabetes Mellitus com Machine Learning

CDC Behavioral Risk Factor Surveillance System — BRFSS 2015

LightGBM	Optuna	SHAP	MLflow	Streamlit

Dataset	CDC BRFSS 2015 — 229.474 pacientes reais
Problema	Classificação binária de diabetes mellitus por autorrelato
Modelo Final	LightGBM otimizado com Optuna (80 trials)
ROC-AUC	0,8192
Recall	0,8168 (81,7% dos diabéticos identificados)
Threshold	0,47 — otimizado por máximo Recall com Precisão mínima
Deploy	Hugging Face Spaces (Streamlit) — acesso público gratuito

Sumário

1. Introdução e Formulação do Problema
2. Dataset — CDC BRFSS 2015
3. Análise Exploratória de Dados (EDA)
4. Pre-processamento e Feature Engineering
5. Modelagem e Comparação de Modelos
6. Otimização com Optuna
7. Ajuste de Threshold
8. Interpretabilidade com SHAP
9. Rastreamento com MLflow
10. Deploy — Hugging Face Spaces
11. Resultados Finais
12. Conclusões

1. Introdução e Formulação do Problema

O diabetes mellitus tipo 2 é uma das doenças crônicas mais prevalentes do mundo. Nos Estados Unidos, onde o dataset BRFSS foi coletado, estima-se que cerca de 38 milhões de pessoas vivam com diabetes e aproximadamente 1 em cada 5 nao sabe que tem a doença. O diagnóstico tardio agrava complicações como doenças cardiovasculares, insuficiência renal e neuropatias, gerando custos humanos e econômicos enormes.

Problema Central

É possível prever se um indíviduo tem diabetes usando apenas variáveis comportamentais, sociodemograficas e de autoavaliação de saúde sem depender de exames laboratoriais como glicemia ou HbA1c? A ideia central e que um modelo treinado nesse tipo de dado poderia funcionar como um triador de baixo custo, identificando pessoas com alta probabilidade de ter diabetes e direcionando-as para exames confirmatórios.

Objetivos

Construir um modelo de classificação binária que estime se um indíviduo tem ou não diabetes e qual a probabilidade associada;

Identificar quais fatores comportamentais e sociodemográficos tem maior poder preditivo;

Comparar múltiplos algoritmos e selecionar o mais adequado para o problema;

Garantir que o modelo minimize falsos negativos, priorizando Recall da classe positiva;

Interpretar o modelo de forma compreensível para profissionais de saúde;

Realizar deploy público e gratuito via Hugging Face Spaces.

Restrição Importante

O modelo deve funcionar sem nenhuma variável laboratorial. Todas as features do BRFSS sao baseadas em autorrelato, pressão arterial alta (diagnosticada por médico), colesterol alto (diagnosticado), IMC calculado a partir de peso e altura declarados, hábitos de atividade física, tabagismo, consumo de álcool e assim por diante. Isso é tanto uma limitação quanto a principal vantagem do modelo em cenários reais de triagem.

2. Dataset — CDC BRFSS 2015

O BRFSS (Behavioral Risk Factor Surveillance System) e o maior sistema de pesquisa telefônica de saúde dos EUA, conduzido anualmente pelo CDC (Centers for Disease Control and Prevention). O dataset utilizado neste projeto e a versão limpa publicada por Alex Teboul no Kaggle, derivada da coleta de 2015.

Atributo	Valor
Registros originais	253.680
Apos remocao de duplicatas	229.474
Features originais	21
Features apos engineering	27
Prevalencia de diabetes	13,9%
Desbalanceamento	6,2:1
Valores nulos	0
Tipo de dados	Survey (autorrelato)
Fonte	CDC / Kaggle

Figura 1 — Distribuicao do target e desbalanceamento entre classes.

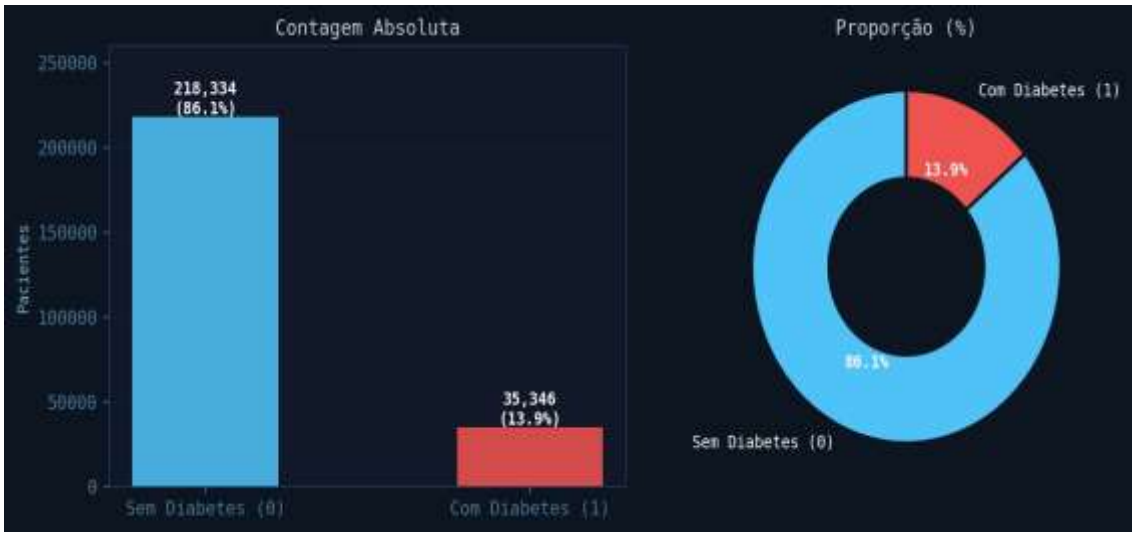

3. Análise Exploratória de Dados (EDA)

A EDA foi conduzida para entender a estrutura dos dados, identificar padroes relevantes e orientar as decisoes de pre-processamento e feature engineering. Os principais achados estao descritos abaixo.

Principais Insights

Desbalanceamento expressivo (6,2:1): 218.334 pacientes sem diabetes (86,1%) contra 35.346 com diagnostico positivo (13,9%). Um modelo trivial que chutasse sempre 0 teria 86% de acurácia confirmando que acurácia não é métrica adequada para este problema.

Fatores de risco mais correlacionados: GenHlth (saude geral autorrelatada) lidera com correlação de +0,294, seguido por HighBP (+0,263), DiffWalk (+0,218) e BMI (+0,217). Esses quatro fatores formam o núcleo preditivo do modelo.

Efeito da idade: A taxa de diabetes cresce monotonicamente com a idade: de 1,4% na faixa 18-24 anos para 21,3% na faixa 75-79 anos, aumento de 15 vezes ao longo da vida adulta.

Acumulo de fatores de risco: Pacientes sem nenhum fator de risco apresentam taxa de DM de apenas 2,5%. Com 5 fatores acumulados (hipertensão + colesterol + obesidade + doença cardíaca + AVC), a taxa sobe para 60%, uma progressao quase linear e clinicamente validada.

Fatores socioeconomicos: Renda e escolaridade mostram gradiente consistente: indíviduos com renda menor que $10k tem taxa de DM de 24,3% contra 8,0% acima de $75k, diferença de 3 vezes. Escolaridade apresenta padrão similar.

Multicolinearidade baixa: Apenas um par de features apresentou correlação acima de 0,5: PhysHlth e GenHlth (r = 0,524). Esse nível é moderado e não requer remoção de variáveis, especialmente para modelos baseados em árvore.

Figura 2 — Correlacao de cada feature com o target (Point-Biserial/Pearson).

4. Pre-processamento e Feature Engineering

Limpeza dos Dados

Foram identificadas 24.206 linhas duplicadas (9,54% do dataset). Como o BRFSS é derivado de uma survey, duplicatas representam respostas coincidentes entre entrevistados distintos, a decisão conservadora foi removê-las para evitar vazamento de informação no treino. Apos a remoção, o dataset passou de 253.680 para 229.474 registros.

O IMC apresentou valor máximo de 98 o que é biologicamente implausivel. Aplicou-se winsorização no percentil 99 (teto = 50,0), reduzindo o desvio padrao de 6,79 para 6,19 sem alterar a mediana ou os quartis, preservando a distribuicao central.

Features Criadas

Feature	Descricao	Motivacao (EDA)
imc_categoria	Categorizacao clinica OMS (0-4)	Inflexao no limiar 30 (obesidade I)
n_fatores_risco	Contagem de 5 fatores acumulados	Taxa de DM: 2,5% (0 fatores) a 60% (5)
idade_x_saude_geral	teracao faixa_etaria x saude_gera	Heatmap mostrou efeito combinado forte
score_saudavel	Sor a de comportamentos protetores (	-5) Agrega fatores protetores da EDA
score_socioeconomico	renda + escolaridade	Gradiente socioeconomico consistente
alto_risco_combinado	Fla : idoso (faixa>=9) e saude ruim (>	4) 37,1% vs 12,6% de prevalencia

Pipeline de Pre-processamento

Foi construído um Pipeline sklearn com dois transformadores encadeados:

Etapa	Transformador	Parametros
1	OutlierClipper (customizado)	lower=0.01, upper=0.99
2	RobustScaler	Centraliza pela mediana, escala pelo IQR

O pipeline é ajustado exclusivamente no conjunto de treino e aplicado ao teste, garantindo ausencia de data leakage. O RobustScaler foi escolhido por sua resistencia a outliers residuais.

Estrategia de Desbalanceamento

Em vez de SMOTE, foi adotado class_weight="balanced" diretamente nos modelos. O BRFSS possui 14 variaveis binarias e o SMOTE interpolaria entre vizinhos gerando valores como 0.3 ou 0.7 para essas variaveis, sem significado clínico. Os pesos calculados foram: Classe 0 = 0,5903 e Classe 1 = 3,2691 (razao de 5,54x), penalizando erros na classe minoritária sem criar dados sintéticos.

5. Modelagem e Comparação de Modelos

Foram treinados 6 modelos: 1 baseline (Regressão Logística) e 5 modelos complexos. A seleção do modelo campeão seguiu dois critérios sequenciais: (1) Recall >= Recall do baseline e esse como critério clínico obrigatório; (2) maior ROC-AUC entre os aprovados.

Baseline — Regressão Logística

A Regressao Logística estabelece o piso mínimo de desempenho. Todo modelo mais complexo precisa superá-la em ROC-AUC e Recall para justificar sua adoção.

Metrica	Valor
ROC-AUC	0,8125
Recall	0,7669
Precisao	0,3177
F1-Score	0,4493
Acuracia	0,7125

Comparação dos Modelos

Modelo	ROC-AUC	Recall	F1	Aprovado?
Baseline (LR)	0,8125	0,7669	0,4493	Referência
Decision Tree	0,8080	0,7789	0,4395	Não (AUC < baseline)
Random Forest	0,8163	0,7733	0,4515	Sim
Gradient Boosting	0,8195	0,1670	0,2603	Não (Recall crítico)
XGBoost	0,8188	0,7847	0,4571	Sim
LightGBM	**0,8190**	**0,7843**	**0,4550**	**Sim — Campeão**

Nota: O Gradient Boosting foi descartado apesar do maior ROC-AUC por apresentar Recall de apenas 16,7% o que é clinicamente inaceitável para uma ferramenta de triagem.

Figura 3 — Comparacao visual de ROC-AUC e Recall entre todos os modelos.

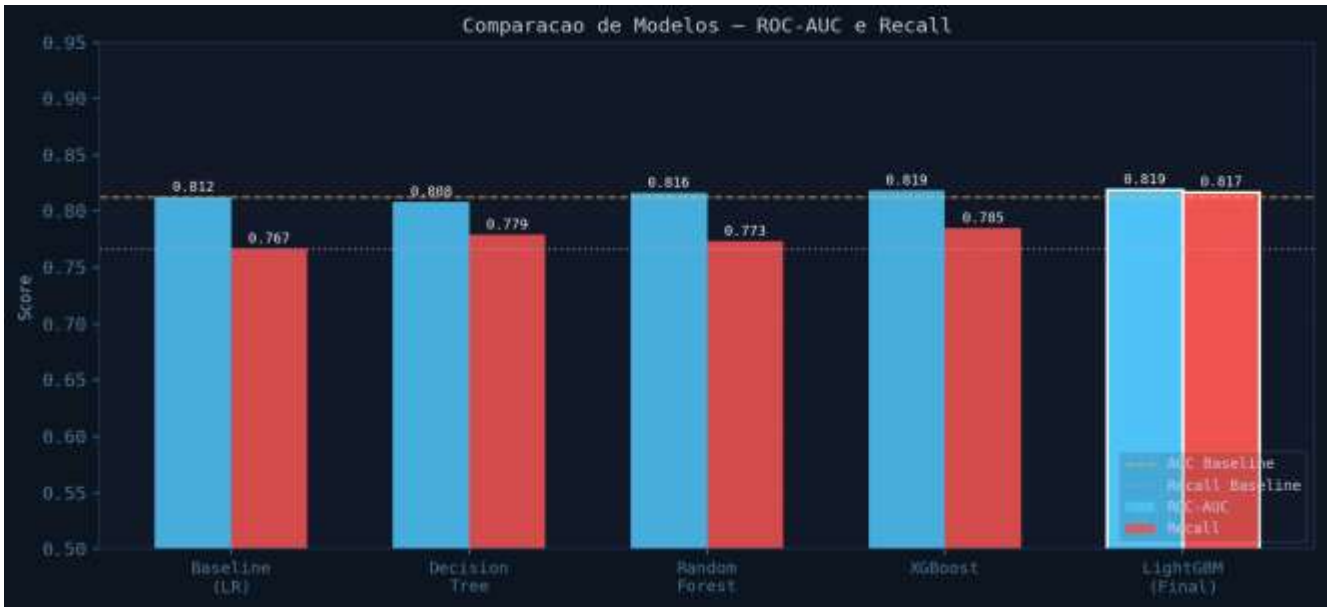

6. Otimização de Hiperparâmetros com Optuna

Após a seleção do LightGBM como modelo campeão, aplicou-se otimização bayesiana de hiperparâmetros com Optuna (TPESampler). A otimização foi realizada apenas no modelo campeão para equilibrar rigor técnico e custo computacional.

Função Objetivo Composta

Em vez de otimizar apenas ROC-AUC, adotou-se uma métrica composta que reflete as prioridades clínicas do projeto:

```
Metrica = 0,5 x AUC + 0,3 x Recall + 0,2 x F1
```

Trials com Recall abaixo do baseline (0,7669) foram descartados automaticamente (retorno 0.0), impedindo o Optuna de explorar regiões clinicamente inaceitáveis. Dos 80 trials executados, 75 foram válidos e 5 descartados.

Melhores Hiperparâmetros

Hiperparametro	Valor Otimo	Range de Busca
n_estimators	163	100 – 500
learning_rate	0,0993	0,01 – 0,20 (log)
max_depth	3	3 – 8
num_leaves	36	20 – 100
subsample	0,885	0,6 – 1,0
colsample_bytree	0,749	0,6 – 1,0
min_child_samples	85	10 – 100

Os hiperparâmetros otimos revelam um modelo deliberadamente raso (max_depth=3, num_leaves=36) com regularização forte (min_child_samples=85), resistente a overfitting e coerente com a baixa variância observada no cross-validation (std <= 0,001).

Figura 4 — Evolução da métrica composta ao longo dos 80 trials do Optuna.

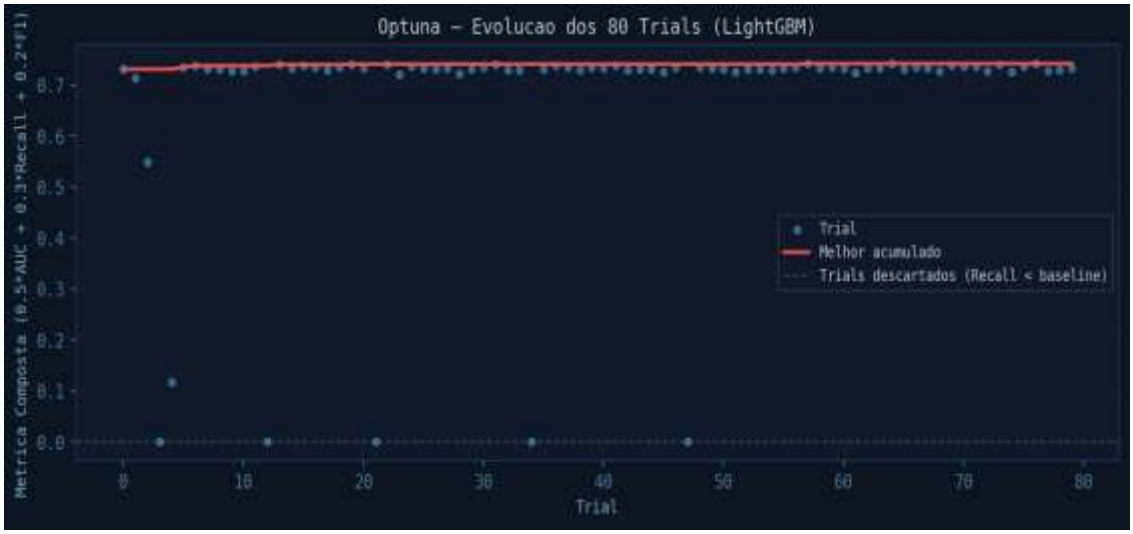

7. Ajuste de Threshold

O threshold padrão de 0,5 não é o ideal para problemas clínicos com desbalanceamento e prioridade em Recall. O critério adotado para seleção do threshold ótimo foi: máximo Recall com Precisão >= 2x a prevalência real da doença (~30%).

Esse piso de precisão evita o caso degenerado onde o modelo classifica praticamente tudo como positivo e na prática significa que pelo menos 1 em cada 3 alertas gerados corresponde a um verdadeiro diabético, proporção defensável para uma triagem de baixo custo onde o próximo passo é um exame confirmatório.

Threshold	Recall	Precisao	F1-Score	Observação
0,50 (padrão)	0,7930	0,3168	0,4527	Padrão sem ajuste
0,65 (por F1)	0,5945	0,4003	0,4784	Sacrifica Recall
0,47 (otimo)	**0,8168**	**0,3059**	**0,4451**	**Escolhido — max Recall**

Figura 5 — Curva Precision-Recall e impacto do threshold nas métricas.

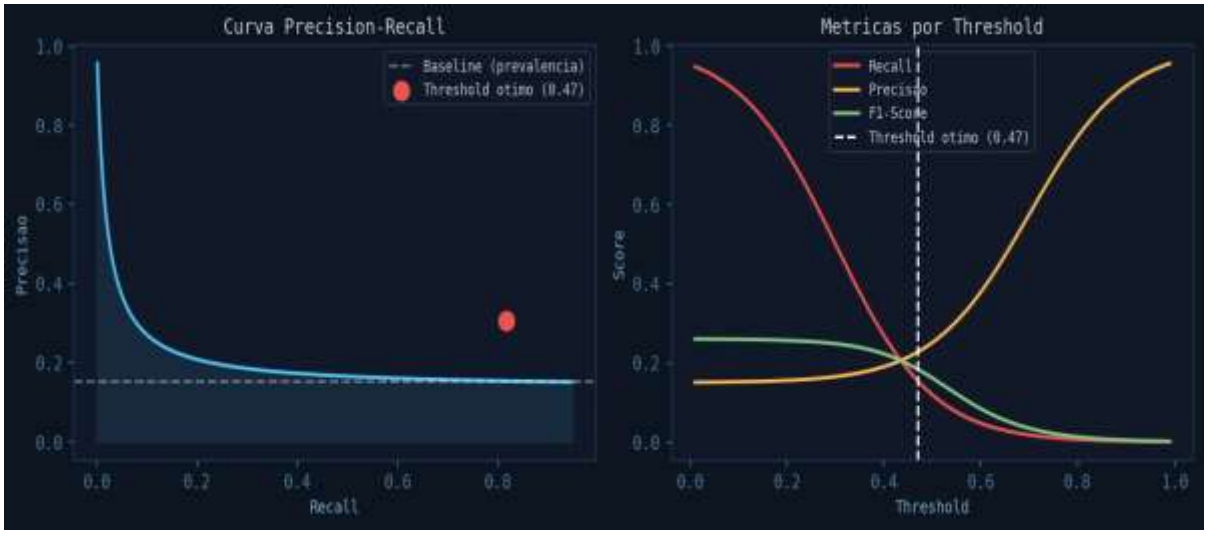

8. Interpretabilidade com SHAP

Os SHAP values (SHapley Additive exPlanations) fornecem explicações locais e globais sobre as predições do modelo, quantificando a contribuição de cada feature para cada predição individual. O TreeExplainer foi utilizado por sua compatibilidade nativa com modelos baseados em árvore (LightGBM).

Principais Achados

idade_x_saude_geral (1º lugar): A feature criada no feature engineering lidera a importância global, superando inclusive as features originais. Valida a decisão de capturar explicitamente a interação entre envelhecimento e percepção de saúde.

n_fatores_risco (2º lugar): A contagem de fatores de risco acumulados e o segundo preditor mais importante, confirmando que o acúmulo de condições clínicas é mais preditivo do que cada condição isolada.

imc e saude_geral (3º e 4º lugar): Features originais com alta correlação na EDA confirmam sua importância no modelo. IMC alto empurra fortemente para o diagnóstico positivo, enquanto saúde autorrelatada ruim e o sinal mais forte da classe positiva.

alcool_pesado (efeito protetor contraintuitivo): Consumo pesado de álcool apresenta impacto negativo consistente e reduz a probabilidade predita. Esse padrãoo, já observado na EDA, reflete o perfil demográfico desse grupo (tipicamente homens mais jovens com outros perfis de saúde).

Figura 6 — Importancia global das features medida pelos SHAP values.

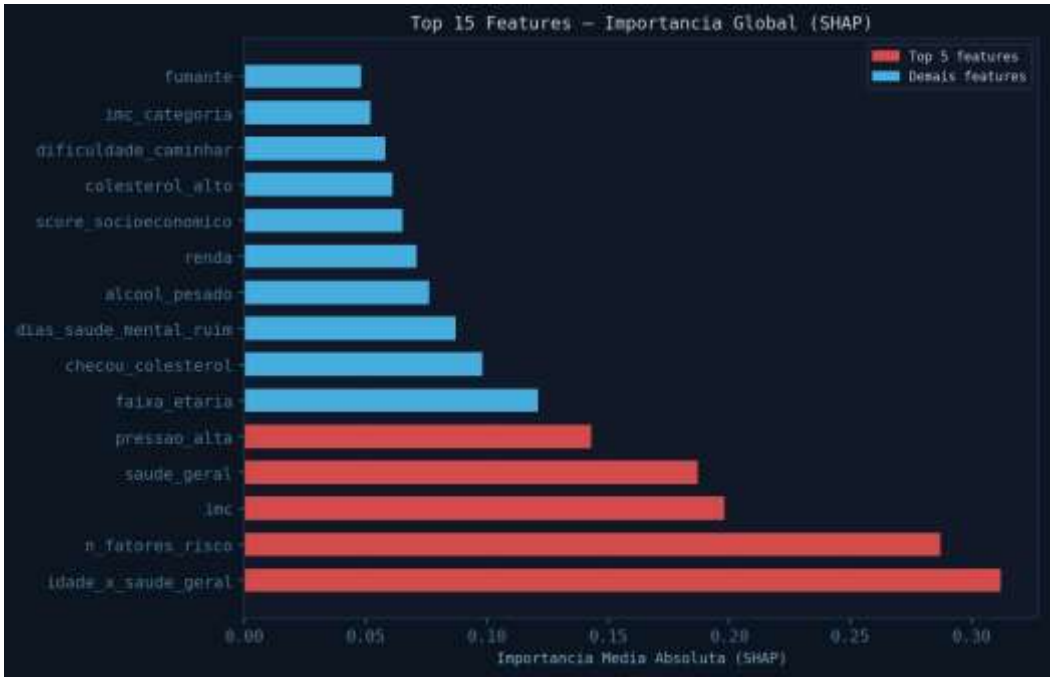

9. Rastreamento de Experimentos com MLflow

Todos os experimentos do projeto foram rastreados com MLflow, criando um histórico completo e reproduzível de todas as decisões de modelagem. O servidor foi executado no Google Colab com acesso externo via tunel ngrok.

Tipo de Run	Quantidade	O que foi registrado
Baseline	1	métricas, parâmetros, modelo serializado
Comparação modelos	5	métricas, tag aprovado_recall, modelo (se aprovado)
Trials Optuna	80	métrica composta, AUC/Recall/F1 por fold (nested runs)
Modelo final	1	Todos os artefatos, métricas com threshold ótimo
TOTAL	87	Runs registradas no experimento

A estrutura de nested runs do Optuna permite visualizar na UI do MLflow os 80 trials expandindo a run pai, com comparação visual automática de métricas entre trials.

10. Deploy — Hugging Face Spaces

O modelo foi publicado como aplicação web pública e gratuita no Hugging Face Spaces, construída com Streamlit. A interface foi projetada para causar impacto visual e ser acessível tanto para usuarios técnicos quanto clínicos.

es tecnicas

s

Especificações Técnicas do Deploy

Componente	Tecnologia/Versão
Framework web	Streamlit 1.41.0
Modelo	LightGBM 4.5.0
Interpretabilidade	SHAP 0.46.0
Plataforma	Hugging Face Spaces (gratuito)
Recursos (free tier)	2 vCPUs, 16GB RAM
Comportamento	Hiberna apos inatividade, acorda em ~30s

11. Resultados Finais

Metricas do Modelo Final

Métrica	Baseline (LR)	LightGBM Final	Ganho
ROC-AUC	0,8125	0,8192	+0,0067
Recall	**0,7669**	**0,8168**	**+0,0499**
Precisao	0,3177	0,3059	-0,0118
F1-Score	0,4493	0,4451	-0,0042
Acuracia	0,7125	0,6900	-0,0225
Threshold	0,50	0,47	Otimizado

Figura 7 — Matriz de confusao do modelo final com threshold=0,47.

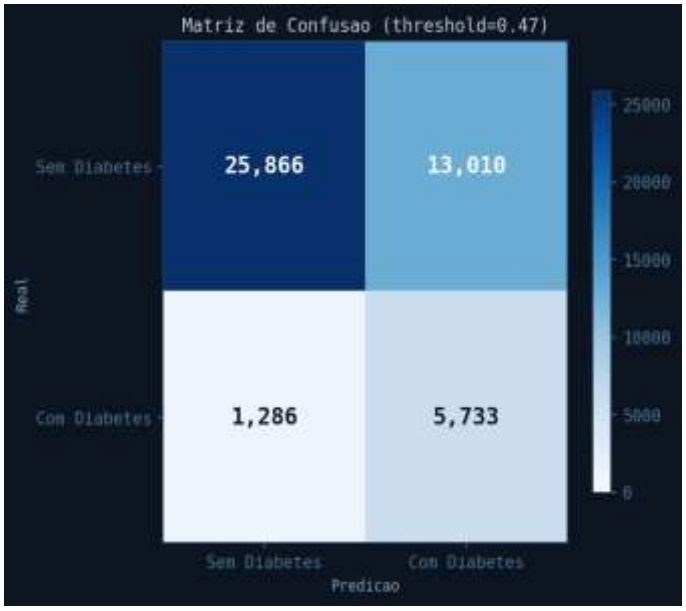

Interpretação Clínica

De 7.019 pacientes diabéticos no conjunto de teste, o modelo identificou corretamente 5.733 (81,7%), deixando de capturar apenas 1.286 falsos negativos. Para a classe negativa, a Precisão de 0,95 é notável

quando o modelo diz que o paciente nao tem diabetes, está certo em 95% dos casos, o que é clinicamente valioso para descartar o diagnóstico com seguranca.

O ganho mais expressivo do projeto nao veio do modelo nem do Optuna, veio do ajuste de threshold, que elevou o Recall de 0,793 para 0,817 ao mudar a métrica de seleção de F1 para Recall com restrição minima de Precisão. Isso reforça uma lição importante: em problemas clínicos com desbalanceamento, a escolha do threshold e tão ou mais impactante que a escolha do algoritmo.

12. Conclusões

Conclusões

- O modelo demonstrou que é possível prever diabetes com ROC-AUC de 0,82 usando apenas variáveis de autorrelato e sem nenhum exame laboratorial.
- A feature criada no feature engineering (idade_x_saude_geral) emergiu como a mais importante do modelo, superando todas as features originais.
- A estrategia class_weight="balanced" mostrou-se superior ao SMOTE para datasets com predominância de variáveis binárias.
- O ajuste de threshold com critério clínico (máximo Recall com Precisão >= 2x prevalência) gerou o maior ganho individual de performance do projeto.
- O Gradient Boosting exemplificou um anti-padrão importante: ROC-AUC alto não garante adequabilidade clínica e o Recall precisa ser avaliado separadamente.
- A integracao MLflow + Optuna + SHAP + Streamlit entregou um projeto completo com rastreabilidade, interpretabilidade e deploy público acessível.

Stack tecnologico: Python 3.10 | LightGBM | scikit-learn | Optuna | SHAP | MLflow | Streamlit | Hugging Face Spaces | Google Colab

Dataset: CDC BRFSS 2015 — kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset